

# España en escenarios

---

**Simulación transparente, evaluación empírica y explicaciones trazables**

Daniel Ribes · Máster en Inteligencia Artificial y Data Science

Defensa del Trabajo Fin de Máster · 28 de septiembre de 2026

# Preguntas y contribuciones

---

1. **Coherencia:** ¿pueden servidor y navegador reproducir un escenario macrofiscal trazable?
2. **Evidencia:** ¿qué apoyan los datos sobre la vivienda y qué añade la transferencia neuronal frente a baselines?
3. **Explicaciones:** ¿qué calidad demuestra el sistema RAG y qué garantías permite afirmar?

Aportaciones: sistema integrado, contrastes reproducibles y comunicación explícita de límites.

# Arquitectura que permite auditar

---

**Fuentes y tablas congeladas → motor Python → API → aplicación React**

- El navegador ejecuta el mismo modelo con anclas compartidas.
- La investigación publica parámetros, métricas y resultados negativos.
- Las explicaciones separan hechos calculados y texto generado.
- Los documentos y el índice RAG son locales; la generación remota envía pasajes seleccionados al proveedor.

La paridad numérica demuestra coherencia de implementación; la evaluación empírica responde otras preguntas.

## Datos: referencia, muestra y fechas

---

- Referencia del escenario: **2026-07-31**; adquisición y construcción se documentan por separado.
- Vivienda: **17 CCAA + Ceuta y Melilla**; Nacional excluido.
- Red global: 1.760 series extranjeras; objetivos de entrenamiento hasta **2019Q3**.
- Distress: **3.874 observaciones, 377 eventos, 154 países** en la muestra evaluada.
- Tablas y resultados sellados con SHA-256; la reconstrucción completa del pipeline original queda fuera del alcance.

Congelar un archivo permite repetir cálculos, sin certificar su autenticidad o eliminar revisiones históricas.

## Identidad de deuda y alcance del escenario

---

$$b_t = b_{t-1} \frac{1 + i_t/100}{1 + g_t^{nom}/100} - pb_t$$

- Coste efectivo y crecimiento nominal en unidades compatibles.
- Saldo primario en puntos de PIB.
- Diez palancas generan desviaciones condicionales sobre la referencia.
- Las elasticidades de comportamiento son principalmente calibraciones.

**Un diferencial negativo ayuda a diluir la deuda heredada. Un déficit primario puede hacer subir la ratio total.**

# Vivienda: una corrección que cambia la dinámica

---


Tasa anual de reversión: **0.2039**. Persistencia: **0.7961**.

$$h_k = \mu + (h_0 - \mu)(1 - \kappa)^k + \text{canales de tipos y crecimiento}$$

- Antes se utilizaba la tasa de reversión como factor de persistencia.
- Python y TypeScript ahora aplican la misma definición.
- El .60 de v16 era persistencia, equivalente a reversión .40.
- La comparación LP acumula log-precios, excluye crecimiento realizado y muestra puntos anuales; su amplitud se normaliza en el primer año.

Media histórica estimada: **1.2151%**. No identifica por sí sola una tendencia estructural.

# La incertidumbre depende de la inferencia



El 3% queda fuera de la banda regional, pero dentro de las bandas que conservan choques nacionales comunes. **Su rechazo no es robusto.** 500 réplicas, semilla 42; sensibilidad condicional a ventana y bloques.

# Transferencia neuronal: resultado negativo

---

| Contraste principal conservado                 | Resultado |
|------------------------------------------------|-----------|
| Regiones donde vence al baseline               | 5/17      |
| Regiones requeridas por el criterio            | 12        |
| MASE candidato (horizontes hasta 4 trimestres) | 0.400     |
| MASE drift                                     | 0.395     |

**Esta configuración no supera al baseline de deriva.** El protocolo usa orígenes móviles y escalado ajustado solo con datos de entrenamiento. El holdout final y la sensibilidad a semillas quedan como trabajo futuro.

## Distress: discriminación, no riesgo calibrado

---

- AUC por grupos de países: **0.674**.
- Average precision: **0.195**.
- El score se muestra en escala 0–1; no como probabilidad para España.
- Muestra seleccionada por disponibilidad de etiquetas; tasa base no representativa del mundo.
- Separar países no equivale a evaluar el futuro con entrenamiento pasado.

Trabajo futuro: negativos representativos, baseline logístico, validación temporal y calibración.

# SHAP y regímenes: lectura descriptiva

---

**Gemelo empírico:**  $R^2$  fuera de país **-0.007**.

- La falta de poder predictivo limita la interpretación de las pendientes SHAP.
- Un intervalo que incluye cero no demuestra que la constante del motor sea correcta.
- SHAP describe asociaciones del predictor; no identifica intervenciones causales.
- Los regímenes HMM describen retrospectivamente la serie y dependen de la especificación.

Estas capas ayudan a explorar hipótesis; su utilidad no convierte sus resultados en pronósticos validados.

# RAG: qué se midió realmente

| Evidencia histórica de desarrollo                | Lectura correcta                                  |
|--------------------------------------------------|---------------------------------------------------|
| 34/35 documentos esperados en top-8              | Recuperación de libro, no corrección de respuesta |
| 10/12 primeras frases citadas con respaldo       | Una frase por respuesta, juicio de otro LLM       |
| Pesos/glosario ajustados sobre preguntas doradas | Conjunto de desarrollo, no test independiente     |

Estas métricas no justifican afirmar ausencia de alucinaciones.

# RAG: alcance medido y protocolo de validación

---

- Comprobación formal de citas y referencias, con fallback ante salida incompleta del modelo.
- Narración: inventario de magnitudes numéricas; no valida completamente signos, unidades o asociación cifra–concepto.
- `grounded` conserva compatibilidad: significa contexto recuperado.
- Protocolo ejecutable: corpus y etiquetas congelados, BM25/dense/híbrido/bilingüe, relevancia de pasajes y revisión humana de afirmaciones.

El protocolo queda especificado y ejecutable; la anotación independiente es trabajo futuro, no un resultado que se presente aquí.

# Análogos: comparación descriptiva corregida


---

**4.070 observaciones completas · 172 países · 1991–2020**

- Consulta en el año seleccionado: deuda, saldo total, crecimiento real, paro e inflación.
- Mahalanobis: covarianza y diferencias en las mismas coordenadas.
- Sin bonus por palanca ni imputación de huecos como valores observados.
- Tipo bancario de préstamo excluido del matching y de cualquier r-g soberano.
- Sin veredicto de sostenibilidad; información estructural no medida se declara ausente.

La semejanza histórica no predice la trayectoria española.

# Monte Carlo: sensibilidad, no cobertura predictiva



4.000 trayectorias, semilla común 42. La amplitud cambia con los supuestos. La banda contiene el 90% central de simulaciones; su cobertura en datos reales no está validada.

# Escenarios ilustrativos actuales - 2050

| Preset | Deuda (% PIB) | Paro (%) | Cuota/salario (%) |
|--------|---------------|----------|-------------------|
| S0     | 223.8         | 10.1     | 35.1              |
| S1     | 310.8         | 10.7     | 45.1              |
| S2     | 224.0         | 10.5     | 35.0              |
| S3     | 213.9         | 10.8     | 39.0              |
| S4     | 180.1         | 9.9      | 35.5              |
| S5     | 223.8         | 8.5      | 35.1              |
| S6     | 282.0         | 10.1     | 35.1              |
| S7     | 357.0         | 11.1     | 45.0              |

Cálculos locales del motor **1.1.0**. Son implicaciones de supuestos mantenidos; no resultados observados ni previsiones.

# Reproducción y pruebas

---

- Dependencias Python restringidas y lock npm; entorno de desarrollo registrado.
- Contratos Python/TypeScript regenerados desde los defaults actuales.
- Crosswalk de países congelado; errores de cobertura visibles.
- Tests ordinarios sin inferencia remota ni corpus privado.
- Checksum de tablas e informes, CI y comandos documentados.

Limitaciones: la instalación limpia no está verificada y algunas transformaciones originales no se han reconstruido. La CI está definida, no ejecutada en remoto.

## Demostración breve

---

1. Abrir S0 y separar dato, supuesto y resultado.
2. Aplicar S1: refinanciación → crecimiento → deuda.
3. Mostrar vivienda: persistencia y bandas alternativas.
4. Buscar un análogo en el año elegido; comprobar qué datos faltan.
5. Contrastar explicaciones deterministas con el alcance de la evidencia RAG.

La demostración se ejecuta sobre el motor regenerado, no sobre capturas anteriores.

# Conclusiones y líneas futuras

---

**Aportación demostrable:** sistema integrado, trazable y evaluable; correcciones científicas reproducibles y resultados negativos publicados.

- La red no supera el baseline principal en el experimento conservado.
- La conclusión sobre crecimiento de vivienda cambia al tratar choques comunes.
- Distress, HMM, SHAP y análogos mantienen alcance exploratorio.
- Líneas futuras: test RAG humano independiente, holdout final de vivienda, evaluación temporal/calibración de distress y reconstrucción completa de fuentes.

La memoria distingue resultados medidos, comprobaciones de software y trabajo futuro.

# Referencias y artefactos

---

- Jordà (2005), *Estimation and Inference of Impulse Responses by Local Projections*.
- Hyndman y Koehler (2006), *Another look at measures of forecast accuracy*.
- Cameron y Miller (2015), *A Practitioner's Guide to Cluster-Robust Inference*.
- Lewis et al. (2020), *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*.
- FMI: marco de riesgo soberano y sostenibilidad de deuda.

Referencias primarias completas: **docs/MEMORIA\_TFM.md**.

Métodos y límites: **docs/RESULTS.md**, **docs/REPRODUCIBILITY.md**.

Artefactos y nuevas sensibilidades: **docs/eval/**.