

España en escenarios

Simulación transparente, evaluación empírica y explicaciones trazables

Daniel Ribes · Máster en Inteligencia Artificial y Data Science

Defensa del Trabajo Fin de Máster · 28 de septiembre de 2026

Preguntas y contribuciones

1. **Coherencia:** ¿pueden servidor y navegador reproducir un escenario macrofiscal trazable?
2. **Evidencia:** ¿qué apoyan los datos sobre la vivienda y qué añade la transferencia neuronal frente a baselines?
3. **Explicaciones:** ¿qué calidad demuestra el sistema RAG y qué garantías permite afirmar?

Aportaciones: sistema integrado, contrastes reproducibles y comunicación explícita de límites.

Arquitectura que permite auditar

Fuentes y tablas congeladas → motor Python → API → aplicación React

- El navegador ejecuta el mismo modelo con anclas compartidas.
- La investigación publica parámetros, métricas y resultados negativos.
- Las explicaciones separan hechos calculados y texto generado.
- Los documentos y el índice RAG son locales; la generación remota envía pasajes seleccionados al proveedor.

La paridad numérica demuestra coherencia de implementación; la evaluación empírica responde otras preguntas.

Datos: referencia, muestra y fechas

- Referencia del escenario: **2026-07-31**; adquisición y construcción se documentan por separado.
- Vivienda: **17 CCAA + Ceuta y Melilla; Nacional excluido**.
- Red global: 1,760 series extranjeras; objetivos de entrenamiento hasta **2019Q3**.
- Distress: **3,874 observaciones, 377 eventos, 154 países** en la muestra evaluada.
- Tablas y resultados sellados con SHA-256; la reconstrucción completa del pipeline original queda fuera del alcance.

Congelar un archivo permite repetir cálculos, sin certificar su autenticidad o eliminar revisiones históricas.

Identidad de deuda y alcance del escenario

$$b_t = b_{t-1} \frac{1 + i_t/100}{1 + g_t^{nom}/100} - pb_t$$

- Coste efectivo y crecimiento nominal en unidades compatibles.
- Saldo primario en puntos de PIB.
- Diez palancas generan desviaciones condicionales sobre la referencia.
- Las elasticidades de comportamiento son principalmente calibraciones.

Un diferencial negativo ayuda a diluir la deuda heredada. Un déficit primario puede hacer subir la ratio total.

Vivienda: una corrección que cambia la dinámica


Tasa anual de reversión: **0.2039**. Persistencia: **0.7961**.

$$h_k = \mu + (h_0 - \mu)(1 - \kappa)^k + \text{canales de tipos y crecimiento}$$

- Antes se utilizaba la tasa de reversión como factor de persistencia.
- Python y TypeScript ahora aplican la misma definición.
- El .60 de v16 era persistencia, equivalente a reversión .40.
- La comparación LP acumula log-precios, excluye crecimiento realizado y muestra puntos anuales; su amplitud se normaliza en el primer año.

Media histórica estimada: **1.2151%**. No identifica por sí sola una tendencia estructural.

La incertidumbre depende de la inferencia



El 3% queda fuera de la banda regional, pero dentro de las bandas que conservan choques nacionales comunes. **Su rechazo no es robusto.** 500 réplicas, semilla 42; sensibilidad condicional a ventana y bloques.

Transferencia neuronal: resultado negativo

Contraste principal conservado	Resultado
Regiones donde vence al baseline	5/17
Regiones requeridas por el criterio	12
MASE candidato (horizontes hasta 4 trimestres)	0.400
MASE drift	0.395

Esta configuración no supera al baseline de deriva. El protocolo usa orígenes móviles y escalado ajustado solo con datos de entrenamiento. El holdout final y la sensibilidad a semillas quedan como trabajo futuro.

Distress: discriminación, no riesgo calibrado

- AUC por grupos de países: **0.674**.
- Average precision: **0.195**.
- El score se muestra en escala 0–1; no como probabilidad para España.
- Muestra seleccionada por disponibilidad de etiquetas; tasa base no representativa del mundo.
- Separar países no equivale a evaluar el futuro con entrenamiento pasado.

Trabajo futuro: negativos representativos, baseline logístico, validación temporal y calibración.

SHAP y regímenes: lectura descriptiva

Gemelo empírico: R^2 fuera de país **-0.007**.

- La falta de poder predictivo limita la interpretación de las pendientes SHAP.
- Un intervalo que incluye cero no demuestra que la constante del motor sea correcta.
- SHAP describe asociaciones del predictor; no identifica intervenciones causales.
- Los regímenes HMM describen retrospectivamente la serie y dependen de la especificación.

Estas capas ayudan a explorar hipótesis; su utilidad no convierte sus resultados en pronósticos validados.

RAG: qué se midió realmente

Evidencia histórica de desarrollo	Lectura correcta
34/35 documentos esperados en top-8	Recuperación de libro, no corrección de respuesta
10/12 primeras frases citadas con respaldo	Una frase por respuesta, juicio de otro LLM
Pesos/glosario ajustados sobre preguntas doradas	Conjunto de desarrollo, no test independiente

Estas métricas no justifican afirmar ausencia de alucinaciones.

RAG: alcance medido y protocolo de validación

- Comprobación formal de citas y referencias, con fallback ante salida incompleta del modelo.
- Narración: inventario de magnitudes numéricas; no valida completamente signos, unidades o asociación cifra–concepto.
- `grounded` conserva compatibilidad: significa contexto recuperado.
- Protocolo ejecutable: corpus y etiquetas congelados, BM25/dense/híbrido/bilingüe, relevancia de pasajes y revisión humana de afirmaciones.

El protocolo queda especificado y ejecutable; la anotación independiente es trabajo futuro, no un resultado que se presente aquí.


Análogos: comparación descriptiva corregida

4,091 observaciones completas · 173 países · 1991–2020

- Consulta en el año seleccionado: deuda, saldo total, crecimiento real, paro e inflación.
- Mahalanobis: covarianza y diferencias en las mismas coordenadas.
- Sin bonus por palanca ni imputación de huecos como valores observados.
- Tipo bancario de préstamo excluido del matching y de cualquier r-g soberano.
- Sin veredicto de sostenibilidad; información estructural no medida se declara ausente.

La semejanza histórica no predice la trayectoria española.

Monte Carlo: sensibilidad, no cobertura predictiva



4,000 trayectorias, semilla común 42. La amplitud cambia con los supuestos. La banda contiene el 90% central de simulaciones; su cobertura en datos reales no está validada.

Escenarios ilustrativos actuales - 2050

Preset	Deuda (% PIB)	Paro (%)	Cuota/salario (%)
S0	223.8	10.1	35.1
S1	306.9	10.7	13.5
S2	221.8	10.5	35.0
S3	210.3	10.8	39.0
S4	206.9	9.9	35.5
S5	223.8	8.5	35.1
S6	282.0	10.1	35.1
S7	349.8	11.1	13.5

Cálculos locales del motor **1.1.0**. Son implicaciones de supuestos mantenidos; no resultados observados ni previsiones.

Reproducción y pruebas

- Dependencias Python restringidas y lock npm; entorno de desarrollo registrado.
- Contratos Python/TypeScript regenerados desde los defaults actuales.
- Crosswalk de países congelado; errores de cobertura visibles.
- Tests ordinarios sin inferencia remota ni corpus privado.
- Checksum de tablas e informes, CI y comandos documentados.

Limitaciones: la instalación limpia no está verificada y algunas transformaciones originales no se han reconstruido. La CI está definida, no ejecutada en remoto.

Demostración breve

1. Abrir S0 y separar dato, supuesto y resultado.
2. Aplicar S1: refinanciación → crecimiento → deuda.
3. Mostrar vivienda: persistencia y bandas alternativas.
4. Buscar un análogo en el año elegido; comprobar qué datos faltan.
5. Contrastar explicaciones deterministas con el alcance de la evidencia RAG.

La demostración se ejecuta sobre el motor regenerado, no sobre capturas anteriores.

Conclusiones y líneas futuras

Aportación demostrable: sistema integrado, trazable y evaluable; correcciones científicas reproducibles y resultados negativos publicados.

- La red no supera el baseline principal en el experimento conservado.
- La conclusión sobre crecimiento de vivienda cambia al tratar choques comunes.
- Distress, HMM, SHAP y análogos mantienen alcance exploratorio.
- Líneas futuras: test RAG humano independiente, holdout final de vivienda, evaluación temporal/calibración de distress y reconstrucción completa de fuentes.

La memoria distingue resultados medidos, comprobaciones de software y trabajo futuro.

Referencias y artefactos

- Jordà (2005), *Estimation and Inference of Impulse Responses by Local Projections*.
- Hyndman y Koehler (2006), *Another look at measures of forecast accuracy*.
- Cameron y Miller (2015), *A Practitioner's Guide to Cluster-Robust Inference*.
- Lewis et al. (2020), *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*.
- FMI: marco de riesgo soberano y sostenibilidad de deuda.

Referencias primarias completas: **docs/MEMORIA_TFM.md**.

Métodos y límites: **docs/RESULTS.md**, **docs/REPRODUCIBILITY.md**.

Artefactos y nuevas sensibilidades: **docs/eval/**.