

Dinero público → Resultados

Defensa del Trabajo de Fin de Máster · Máster en Data Science (Evolve)

Daniel Ribes · julio 2026 · github.com/danribes/tfm-data-science

El problema y la evolución del proyecto

- **Pregunta:** ¿qué obtiene un país (y una CCAA) a cambio de su gasto público?
- Origen avalado: **índice de asequibilidad de vivienda por CCAA** (entregas 1–3)
- Evolución: la vivienda es una partida más (GF06) → el marco general la **contiene y conserva como núcleo**
- El feedback del tutor, convertido en especificación verificable:
 - ratio SIEMPRE como indicador aproximado + medida de esfuerzo real
 - **MVP primero:** nada bloquea el núcleo
 - "el formato de entrega funciona como un contrato" → el repositorio ES la entrega

Arquitectura de datos

```
connectors/ → raw (vintage) → processed (32) → gold (11) → analysis · api · app
```

- Más de **30 fuentes públicas**: INE, BdE, Eurostat, FMI, OMS, Banco Mundial, GMD/JST (1870–2023), UN DESA, MITMA
- `vintage_manifest.csv`: qué versión del dato existía en cada descarga
- **51 tests automáticos** del contrato de datos y modelos
- Nada entra en gold sin clave primaria verificada y smoke test

La calidad de datos como resultado

- 3 bugs de pipeline detectados, corregidos y blindados con test de regresión:
 - IPC: promediaba 1.120 series en vez de filtrar la general
 - IPV trimestral: se descargaba pero no se persistía
 - `str.split(". ")` de pandas es REGEX → rompía las CCAA compuestas (ratio solo en 8 de 18 territorios)
- El riesgo declarado en la Entrega 2 **se materializó**: el INE renumeró las tablas del IPV (49300/76201 → 80271/80270) — la mitigación prevista funcionó

Metodología: protocolo pre-registrado


Los criterios se fijan antes de mirar; endurecerlos vale, relajarlos no.

1. EDA con decisiones vinculantes (transformación, pooling, exógenas)
2. Baselines difíciles ANTES de los candidatos
3. Validación rolling-origin con guardas anti-fuga verificadas por tests
4. **Test final de un solo uso** (2024–2025), regla de decisión escrita en el código
5. Multiverso: sin estabilidad entre especificaciones, no se publica
6. Incertidumbre SIEMPRE visible

T1 · La vara a batir no era la esperada


- Naive estacional: MASE 0,89 — cómodo porque la escala la infla la crisis 2008–14
- **El drift (tendencia reciente): MASE 0,40** — imbatido en las 18 series, COVID incluido
- El criterio de aceptación se **ENDURECIÓ antes de entrenar candidatos**: batir al drift en ≥ 12 de 17 CCAA
- Sin ese endurecimiento, los tres candidatos habrían "aprobado"

T1 · El test final evitó publicar un desplome




SARIMAX 1/17 · GBM 0/17 en validación corta; la hipótesis "GBM gana a largo" quedó **refutada 0/17**: pronosticó caída en pleno boom (reversión aprendida de la crisis)

T1 • Pronóstico de producción




- Drift + **abanico empírico 80/95 %** (asimétrico: el drift se queda corto en booms)
- **Ratio nacional: 1,26 (2024) → ~1,5–1,6 (2027) incluso con salarios al 2 %**

El driver de oferta: la señal más fuerte del proyecto




- Permisos residenciales: $r = 0,57$ con 11 trimestres de adelanto; avisó del giro 2013–14 con 3 trimestres
- Pata regional (licencias MITMA): colapso $\times 24$ (737.186 → 31.236 viviendas/año)
- Disciplina: se adoptará solo si lo confirman los datos de 2026+

Atlas fiscal · la figura que exige contexto




La palanca pública de vivienda (0,5 % PIB) es un orden de magnitud menor que la promoción privada (5,8 % PIB) — contexto obligatorio de cualquier conclusión

A1 · Rendimiento sanitario: nunca una liga



- España: **+2,7 ± 3,5 años** — por encima de lo esperado, DENTRO de su banda
- Hallazgo honesto: hasta el OLS empata con la mediana del grupo de renta — **la renta domina**

D1 · Escenarios de deuda: la demografía domina



- Central 2050: **224 %PIB** (banda 198–267) vs 127 % sin envejecimiento
- Ninguna palanca aislada estabiliza; el menú cuantifica, no prescribe

El producto (MVP)

- **API FastAPI:** pronóstico con abanico, funnel, menú de escenarios, simulador interactivo con palancas r/g/pb
- **Dashboard Streamlit** de 4 pestañas con "TU SENDA" sobre el menú
- La honestidad viaja en el payload: "no es un ranking", "la banda es la parte informativa"
- Todo servido desde artefactos gold pre-computados y testeados

¿Y esto no lo hace un LLM?

	LLM	Este sistema
El número	recordado del texto de entrenamiento	calculado de datos con cadena de custodia
Evaluación	no puede suspender un backtest	suspendió tres veces en público — prueba de que es real
Incertidumbre	tono de confianza	cuantiles medidos, conformal, cobertura comprobable
Reproducibile	varía con prompt y versión	mismo código+datos → mismos números (51 tests)
Lo normativo	prescribe con soltura	pone precio y devuelve la elección a la política

Declaración: LLM usado como herramienta de proceso (código, redacción), nunca como fuente de números. **El LLM narra; el sistema calcula.**

Conclusiones

1. Solo con fuentes públicas y código abierto: **datos** → **modelos** → **producto**, con trazabilidad profesional
2. **La aportación diferencial es la disciplina**: tres veces el modelo flexible perdió bajo reglas pre-registradas; una vez el protocolo evitó publicar una predicción de desplome en pleno boom
3. Sustantivo: la asequibilidad no se corrige sola; la palanca pública de vivienda es pequeña frente a la privada; la renta domina el rendimiento sanitario; la demografía domina la deuda

Trabajo futuro y cierre

- Driver de oferta en la parrilla de validación con datos 2026+
- Cuota hipotecaria teórica (falta €/m²) · panel quinquenal para A1 · episodios históricos de consolidación
- Actualización trimestral: cada IPV nuevo re-ejecuta pipeline → gold → pronóstico

Gracias.

github.com/danribes/tfm-data-science · `docs/MEMORIA.md` · `streamlit run app/dashboard.py`