

Dinero público → Resultados

Defensa del Trabajo de Fin de Máster · Máster en Data Science (Evolve)

Daniel Ribes · julio 2026 · github.com/danribes/tfm-data-science

El problema y la evolución del proyecto

- **Pregunta:** ¿qué obtiene un país (y una CCAA) a cambio de su gasto público?
- Origen avalado: **índice de asequibilidad de vivienda por CCAA** (entregas 1–3)
- Evolución: la vivienda es una partida más (GF06) → el marco general la **contiene y conserva como núcleo**
- El feedback del tutor, convertido en especificación verificable:
 - ratio SIEMPRE como indicador aproximado + medida de esfuerzo real
 - **MVP primero:** nada bloquea el núcleo
 - "el formato de entrega funciona como un contrato" → el repositorio ES la entrega

Arquitectura de datos

```
connectors/ → raw (vintage) → processed (32) → gold (11) → analysis · api · app
```

- Más de **30 fuentes públicas**: INE, BdE, Eurostat, FMI, OMS, Banco Mundial, GMD/JST (1870–2023), UN DESA, MITMA
- `vintage_manifest.csv`: qué versión del dato existía en cada descarga
- **51 tests automáticos** del contrato de datos y modelos
- Nada entra en gold sin clave primaria verificada y smoke test

La calidad de datos como resultado

- 3 bugs de pipeline detectados, corregidos y blindados con test de regresión:
 - IPC: promediaba 1.120 series en vez de filtrar la general
 - IPV trimestral: se descargaba pero no se persistía
 - `str.split(". ")` de pandas es REGEX → rompía las CCAA compuestas (ratio solo en 8 de 18 territorios)
- El riesgo declarado en la Entrega 2 **se materializó**: el INE renumeró las tablas del IPV (49300/76201 → 80271/80270) — la mitigación prevista funcionó

Metodología: protocolo pre-registrado


Los criterios se fijan antes de mirar; endurecerlos vale, relajarlos no.

1. EDA con decisiones vinculantes (transformación, pooling, exógenas)
2. Baselines difíciles ANTES de los candidatos
3. Validación rolling-origin con guardas anti-fuga verificadas por tests
4. **Test final de un solo uso** (2024–2025), regla de decisión escrita en el código
5. Multiverso: sin estabilidad entre especificaciones, no se publica
6. Incertidumbre SIEMPRE visible

T1 · La vara a batir no era la esperada


- Naive estacional: MASE 0,89 — cómodo porque la escala la infla la crisis 2008–14
- **El drift (tendencia reciente): MASE 0,40** — imbatido en las 18 series, COVID incluido
- El criterio de aceptación se **ENDURECIÓ antes de entrenar candidatos**: batir al drift en ≥ 12 de 17 CCAA
- Sin ese endurecimiento, los tres candidatos habrían "aprobado"

T1 · El test final evitó publicar un desplome




SARIMAX 1/17 · GBM 0/17 en validación corta; la hipótesis "GBM gana a largo" quedó **refutada 0/17**: pronosticó caída en pleno boom (reversión aprendida de la crisis)

T1 • Pronóstico de producción




- Drift + **abanico empírico 80/95 %** (asimétrico: el drift se queda corto en booms)
- **Ratio nacional: 1,26 (2024) → ~1,5–1,6 (2027) incluso con salarios al 2 %**

El driver de oferta: la señal más fuerte del proyecto




- Permisos residenciales: $r = 0,57$ con 11 trimestres de adelanto; avisó del giro 2013–14 con 3 trimestres
- Pata regional (licencias MITMA): colapso $\times 24$ (737.186 → 31.236 viviendas/año)
- Disciplina: se adoptará solo si lo confirman los datos de 2026+

Atlas fiscal · la figura que exige contexto




La palanca pública de vivienda (0,5 % PIB) es un orden de magnitud menor que la promoción privada (5,8 % PIB) — contexto obligatorio de cualquier conclusión

A1 · Rendimiento sanitario: nunca una liga



- España: **+2,7 ± 3,5 años** — por encima de lo esperado, DENTRO de su banda
- Hallazgo honesto: hasta el OLS empata con la mediana del grupo de renta — **la renta domina**

D1 · Escenarios de deuda: la demografía domina



- Central 2050: **224 %PIB** (banda 198–267) vs 127 % sin envejecimiento
- Ninguna palanca aislada estabiliza; el menú cuantifica, no prescribe

El producto (MVP)

- **API FastAPI:** pronóstico con abanico, funnel, menú de escenarios, simulador interactivo con palancas r/g/pb
- **Dashboard Streamlit** de 4 pestañas con "TU SENDA" sobre el menú
- La honestidad viaja en el payload: "no es un ranking", "la banda es la parte informativa"
- Todo servido desde artefactos gold pre-computados y testeados

Conclusiones

1. Solo con fuentes públicas y código abierto: **datos** → **modelos** → **producto**, con trazabilidad profesional
2. **La aportación diferencial es la disciplina**: tres veces el modelo flexible perdió bajo reglas pre-registradas; una vez el protocolo evitó publicar una predicción de desplome en pleno boom
3. Sustantivo: la asequibilidad no se corrige sola; la palanca pública de vivienda es pequeña frente a la privada; la renta domina el rendimiento sanitario; la demografía domina la deuda

Trabajo futuro y cierre

- Driver de oferta en la parrilla de validación con datos 2026+
- Cuota hipotecaria teórica (falta €/m²) · panel quinquenal para A1 · episodios históricos de consolidación
- Actualización trimestral: cada IPV nuevo re-ejecuta pipeline → gold → pronóstico

Gracias.

github.com/danribes/tfm-data-science · `docs/MEMORIA.md` · `streamlit run app/dashboard.py`